# AIRFLOW + SPARK STANDALONE

Ghi chú ôn tập nhanh | Realtime-data-streaming-pipeline | 2 trang

> **Tư duy cốt lõi: Airflow điều phối workflow; SparkSubmitOperator gọi spark-submit; Driver điều phối xử lý; Master cấp tài nguyên; Worker chạy Executors.**

## 01 | Vai trò từng thành phần

| Thành phần | Cần nhớ |
|---|---|
| **Airflow DAG / Task** | Định nghĩa workflow, dependencies, lịch chạy, retry và logs. |
| **SparkSubmitOperator** | Operator trong DAG gọi **spark-submit** thông qua Spark provider; import thành công không đồng nghĩa đã tạo task. |
| **Airflow Connection** | Lưu thông tin truy cập Spark Master (ID, type, host, port). Không phải kết nối luôn mở. |
| **Spark Driver** | Chia job thành stages/tasks, lập lịch và giao tiếp trực tiếp với Executors. |
| **Spark Master** | Điều phối tài nguyên của Spark Standalone; không thực thi transformation. |
| **Worker / Executor** | Worker quản lý tài nguyên node; Executors chạy Spark tasks và xử lý dữ liệu. |

## 02 | Cơ chế thực thi ở Client Mode

```
Airflow DAG Task (LocalExecutor)
  -> SparkSubmitOperator -> spark-submit
  -> Spark Driver (trong container chạy spark-submit)
  -> Spark Master (spark://spark-master:7077)
  -> Spark Worker -> Executors -> Spark Tasks
```

• **Driver** thường chạy tại **airflow-scheduler** trong cấu hình hiện tại. Master phân bổ tài nguyên; Driver liên lạc trực tiếp với Executors.

• **Client mode**: Worker/Executors phải truy cập ngược được Driver qua Docker network (vì vậy cần cấu hình `spark.driver.host`).

• Spark có thể chạy độc lập bằng `spark-submit`; Airflow bổ sung scheduling, retries, dependencies và giám sát.

## 03 | Docker Compose và tái sử dụng images

| Giữ lại | Cần tách / chỉnh sửa |
|---|---|
| **Images:** twibot22-airflow:3.0.0, twibot22-spark:3.5.3 | Đặt **name: realtime-streaming**; tách volumes/metadata PostgreSQL, DAGs, logs. |
| **LocalExecutor** và Spark Standalone Master–Worker | Bỏ **build** nếu dùng image có sẵn; dùng **pull_policy: never**. |
| **DNS nội bộ:** spark-master:7077 | Đổi cổng host UI (Airflow 8091, Master 8092, Worker 8093) nếu chạy song song. |

**Layout đề xuất:** `compose.yaml` tại root; `airflow/{dags,config,logs,plugins}`; `spark/` và `jobs/` cùng cấp. Bind mount host thay đổi, nhưng đường dẫn **trong container** giữ nguyên.

# CONNECTION & VẬN HÀNH

Các cách cấu hình, ví dụ SparkSubmitOperator, lệnh kiểm tra và lỗi thường gặp

## 04 | spark_default: ý nghĩa và 3 cách tạo

`conn_id="spark_default"` là ID để DAG tìm cấu hình Spark Master. Sau khi tạo Airflow metadata DB mới, Connection của Twibot22 **không tự chuyển sang** project mới.

| Cách cấu hình | Đặc điểm |
|---|---|
| **CLI** - airflow connections add | Tạo record trong Airflow metadata PostgreSQL; còn sau restart nếu giữ volume. |
| **Airflow UI** - Connections | Điền Connection ID / Type / Host / Port; giống CLI về nơi lưu. |
| **Compose environment** | AIRFLOW_CONN_SPARK_DEFAULT; đọc từ env, không lưu DB và thường không xuất hiện trong UI. |

```
docker compose exec airflow-scheduler airflow connections add spark_default
  --conn-type spark --conn-host spark://spark-master --conn-port 7077
docker compose exec airflow-scheduler airflow connections get spark_default
```

**PowerShell:** dòng `connections  add` ở trên là minh họa có xuống dòng để đọc; khi chạy hãy viết thành **một dòng** hoặc nối bằng dấu backtick (`).

## 05 | Cấu hình SparkSubmitOperator tối thiểu

```
SparkSubmitOperator(
    task_id="test_spark",
    conn_id="spark_default",
    application="/opt/airflow/project/jobs/test_spark.py",
    deploy_mode="client",
    conf={
        "spark.driver.host": "airflow-scheduler",
        "spark.driver.bindAddress": "0.0.0.0",
        "spark.pyspark.python": "python3.12",
        "spark.pyspark.driver.python": "python3.12",
    },
)
```

**Phân biệt:** `application` là script **trong container**; `conn_id` xác định Master; `driver.host` là hostname Worker truy cập được; `bindAddress` là IP Driver lắng nghe.

## 06 | Lệnh kiểm tra và Python compatibility

```
docker compose config --quiet
docker compose up -d --no-build
docker compose ps -a
docker compose exec airflow-scheduler spark-submit --version
docker compose exec airflow-scheduler airflow connections get spark_default
docker compose exec spark-worker python3.12 --version
```

**Đã xác nhận:** Airflow Driver Python **3.12.10**; Spark Worker có Python **3.12.15**, nhưng `python3` mặc định là **3.8.10**. Cần chỉ định `python3.12` hai phía; major/minor phải khớp, patch có thể khác.

## 07 | Chẩn đoán lỗi và điều kiện hoàn thành

| Dấu hiệu | Kiểm tra đầu tiên |
|---|---|
| **Connection not found** | Tạo spark_default bằng CLI/UI/env; kiểm tra đúng metadata DB. |
| **Không submit được** | Kiểm tra spark-submit, Spark provider, service DNS và Master URL. |
| **Executors không kết nối** | Kiểm tra driver.host, network và khả năng kết nối ngược từ Worker. |
| **Python mismatch / file not found** | Kiểm tra python3.12, bind mounts, đường dẫn application và dependencies/JAR. |

**Milestone PASS:** Airflow UI mở được; Spark Master thấy Worker ALIVE; Connection hợp lệ; DAG submit thành công; Spark UI có application; task hoàn tất và logs rõ ràng.